Multi-step Prediction with Uncertainty

Τεχνητή Νοημοσύνη ΙΙ

Στρατηγός - Αφράτης Νικόλαος: 1092637

Τσικνάκης Εμμανουήλ: 1092861

Τρύφων Αντώνιος: 1092622

Στραβομύτης Βελισσάριος - Βησαρίων: 1092801



26 Ιουνίου 2026

Περιεχόμενα

1 Περίληψη **2**

2 Εισαγωγή **2**

3 Συλλογή και Περιγραφή Δεδομένων. **3**
3.1 Περιγραφή του περιβάλλοντος CartPole. 3
3.2 Διαδικασία Συλλογής Δεδομένων. 4

4 Μοντέλα πρόβλεψης **7**
4.1 Ντετερμινιστικό μοντέλο πρόβλεψης ενός βήματος 7
4.1.1 Αποτελέσματα ντετερμινιστικής πρόβλεψη ενός βήματος . . . 7
4.2 Ντετερμινιστικό μοντέλο πρόβλεψης πολλαπλών βημάτων 8
4.2.1 Αποτελέσματα ντετερμινιστικής πρόβλεψης πολλαπλών βημάτων 8
4.3 Πιθανοτικό μοντέλο πρόβλεψης επόμενης κατάστασης με αβεβαιότητα 9
4.4 Ensemble Νευρωνικό Δίκτυο πρόβλεψης επόμενης κατάστασης . . . 10

5 Μέθοδοι Διάδοσης Αβεβαιότητας σε Πολυβηματικές Προβλέψεις **12**
5.1 Deterministic Mean Propagation 12
5.2 Monte Carlo Propagation 13
5.3 Moment Matching 14

6 Συγκριτική Αξιολόγηση των Μεθόδων Διάδοσης της Αβεβαιότητας **15**
6.1 Ανάλυση Σφάλματος Πρόβλεψης και Συσσώρευσης Ολίσθησης . . . 15
6.2 Δυναμική Εξέλιξη και Επέκταση της Προβλεπόμενης Διακύμανσης . 15
6.3 Στατιστική Βαθμονόμηση (Calibration) και Αξιοπιστία 16
6.4 Συμπεράσματα Σύγκρισης 17
6.5 Γραφικές παραστάσεις 18

7 Συνολική Σύνθεση της Δυναμικής Διάδοσης της Αβεβαιότητας σε Προβλέψεις Μεγάλου Χρονικού Ορίζοντα **20**
7.1 Μηχανισμός Συσσώρευσης Σφαλμάτων στις Πολυβηματικές Προβλέψεις 20
7.2 Επίδραση της Μοντελοποίησης της Αβεβαιότητας στις Μακροπρόθεσμες Προβλέψεις 20
7.3 Χρονική Εξέλιξη της Αβεβαιότητας του Συστήματος 21
7.4 Όρια Αξιοπιστίας του Προβλεπτικού Μοντέλου 21
7.5 Περιορισμοί των Μεθόδων που Βασίζονται σε Δειγματοληψία 21

1. Περίληψη

Η παρούσα εργασία πραγματεύεται το πρόβλημα της πρόβλεψης πολλαπλών χρονικών βημάτων σε δυναμικά συστήματα δίνοντας έμφαση στην εκτίμηση και κατ' επέκταση στην διάδοσή (καθώς ο χρόνος περνά) της αβεβαιότητας των προβλέψεων για το εκάστοτε δυναμικό σύστημα. Στόχος είναι η ανάπτυξη καθώς και η αξιολόγηση μοντέλων που θα μπορούν τόσο να προβλέψουν την χρονική εξέλιξη και την διαδοχή των καταστάσεων ενός δυναμικού συστήματος, που ξεκινά από κάποια αρχική κατάσταση, όσο και την αξιοπιστία της πρόβλεψης. Αρχικά υλοποιείται ένα απλό ντετερμινιστικό μοντέλο, απλό MLP, ενώ στην συνέχεια δημιουργούνται μοντέλα τα οποία έχουν την δυνατότητα εκτίμησης αβεβαιότητας. Η αξιολόγηση βασίζεται στη σύγκριση της ακρίβειας της πρόβλεψης και της εξέλιξης τους σφάλματος στον χρόνο.

2. Εισαγωγή

Η πρόβλεψη της μελλοντικής εξέλιξης δυναμικών συστημάτων αποτελεί ένα από τα σημαντικότερα προβλήματα στους τομείς της Τεχνητής Νοημοσύνης και της Μηχανικής Μάθησης. Η δυνατότητα ακριβής πρόβλεψης μελλοντικών καταστάσεων στις οποίες το σύστημα μπορεί να καταλήξει αποτελεί βασικό στοιχείο σε εφαρμογές όπως η αυτόνομη οδήγηση, η ρομποτική, γενικότερα συστήματα αυτομάτου ελέγχου. Ωστόσο, όσο αυξάνεται ο χρονικός ορίζοντας, δηλαδή όσο αυξάνεται το χρονικό διάστημα για το οποίο χρειάζεται να γίνουν προβλέψεις, τόσο αυξάνεται και η αβεβαιότητα για την επόμενη κατάσταση. Αυτό γίνεται διότι μικρά σφάλματα στις αρχικές εκτιμήσεις μπορούν να συσσωρευτούν κατά την διάρκεια των διαδοχικών προβλέψεων οδηγώντας σε μεγάλη απόκλιση από την πραγματική εξέλιξη του συστήματος.

Ως λύση σε αυτό το πρόβλημα έρχεται η ανάπτυξη μοντέλων που, εκτός από την πρόβλεψη της επόμενης κατάστασης έχουν την δυνατότητα εκτίμησης αβεβαιότητας των προβλέψεων που παρέχουν. Η πληροφορία αυτή είναι ιδιαίτερα σημαντική σε εφαρμογές όπου οι αποφάσεις λαμβάνονται μέσω προβλέψεων κάποιου μοντέλου καθώς παρέχει ένα μέτρο αξιοπιστίας των αποτελεσμάτων.

Στην παρούσα εργασία το δυναμικό σύστημα που μελετάται είναι το CartPole figure 1, μέσω του περιβάλλοντος προσομοίωσης της βιβλιοθήκης gymnasium της Python. Αποτελείται από μία ράβδο συνδεδεμένη μέσω μιας ελεύθερης άρθρωσης σε ένα αμαξίδιο, το οποίο κινείται κατά μήκος μια τροχιάς χωρίς τριβές. Η ράβδος τοποθετείται σε όρθια θέση πάνω στο αμαξίδιο και στόχος είναι η ισορροπία της ράβδου εφαρμόζοντας δυνάμεις προς την αριστερή και τη δεξιά κατεύθυνση στο αμαξίδιο.

Για την εκπαίδευση των μοντέλων συλλέχθηκε σύνολο δεδομένων μέσω της καταγραφής μεγάλου αριθμού επεισοδίων στο περιβάλλον της Gymnasium. Η καταγραφή των δεδομένων έγινε με τρόπο τέτοιο ώστε να εξασφαλισθεί η κάλυψη όσο το δυνατό μεγαλύτερου μέρους του χώρου καταστάσεων.

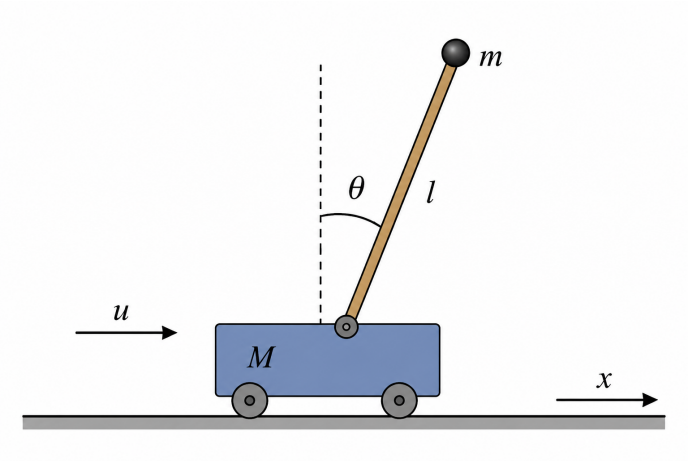


Figure 1: Cartpole system.

3. Συλλογή και Περιγραφή Δεδομένων.

3.1 Περιγραφή του περιβάλλοντος CartPole.

Για τις ανάγκες της εργασίας χρησιμοποιήθηκε το περιβάλλον προσομοίωσης CartPole-v1 της Gymnasium. Στο συγκεκριμένο περιβάλλον η ράβδος είναι συνδεδεμένη στο αμαξίδιο το οποίο έχει την δυνατότητα κίνησης κατά μήκος του οριζόντιου άξονα. Υπάρχουν δύο πιθανές ενέργειες, η άσκηση δύναμης προς τα δεξιά και αυτή προς τα αριστερά. Η κατάσταση του συστήματος περιγράφεται από ένα διάνυσμα τεσσάρων πραγματικών μεταβλητών, την θέση του αμαξιδίου στον χώρο και την ταχύτητά του καθώς και την γωνία της ράβδου και την γωνιακή ταχύτητα αυτής. Επίσης άλλη μία μεταβλητή που παίρνει τιμές 0 ή 1 περιγράφει την ενέργεια, βάσει της οποίας το σύστημα θα οδηγηθεί στην επόμενη κατάσταση. Το διάνυσμα κατάστασης φαίνεται παρακάτω.

$$\mathbf{x}_t = \begin{bmatrix} x_t \\ \dot{x}_t \\ \theta_t \\ \dot{\theta}_t \end{bmatrix}, \qquad a_t \in \{0, 1\}.$$

Το περιβάλλον CartPole-v1 ορίζει συγκεκριμένα όρια για τις μεταβλητές κατάστασης, τα οποία καθορίζουν πότε θεωρείται ότι το σύστημα έχει αποτύχει να διατηρήσει την ισορροπία της ράβδου και συνεπώς την λήξη του πειράματος/επεισοδίου.

Table 1: Μεταβλητές κατάστασης του περιβάλλοντος CartPole-v1 και αντίστοιχα όρια τερματισμού επεισοδίου.

Μεταβλητή	**Σύμβολο**	**Όριο τερματισμού**
Θέση αμαξιδίου	x	$[-2.4,\ 2.4]$ m
Ταχύτητα αμαξιδίου	$\dot{x}$	Δεν υπάρχει όριο τερματισμού
Γωνία ράβδου	θ	$[-0.2095,\ 0.2095]$ rad ($\pm 12^{\circ}$)
Γωνιακή ταχύτητα ράβδου	$\dot{\theta}$	Δεν υπάρχει όριο τερματισμού

3.2 Διαδικασία Συλλογής Δεδομένων.

Η συλλογή των δεδομένων πραγματοποιήθηκε μέσω εκτέλεσης επεισοδίων στο περιβάλλον CartPole-v1. Κάθε επεισόδιο παρήγαγε μία τροχιά χρονικών βημάτων κατά την διάρκεια της οποίας καταγράφονταν σε κάθε χρονική στιγμή η κατάσταση του συστήματος, η ενέργεια που εφαρμόστηκε και η επόμενη κατάσταση που προέκυπτε από την δυναμική του συστήματος. Με τον τρόπο αυτό δημιουργήθηκε ένα σύνολο μεταβάσεων της μορφής:

$$(\mathbf{x}_t, a_t, \mathbf{x}_{t+1}).$$

Σε κάθε επόμενη κατάσταση που προέκυπτε προσθέτονταν σταθερού πλάτους θόρυβος, που μοντελοποιεί πιθανά λάθη ή έλλειψη ακρίβειας κατά την διάρκεια καταγραφής των δεδομένων και τελικά η επόμενη κατάσταση μπορεί να περιγραφεί ως εξής:

$$\mathbf{x}_{t+1} = f(\mathbf{x}_t, a_t) + \epsilon_t,$$

όπου ε ο προστιθέμενος θόρυβος και f η δυναμική του συστήματος.

Με σκοπό την δημιουργία ενός συνόλου δεδομένων που θα εξασφαλίζει όσο δυνατή μεγαλύτερη κάλυψη του χώρου καταστάσεων χωρίς μεγάλη υπολογιστική επιβάρυνση η επιλογή των ενεργειών έγινε με δύο πολιτικές. Το 5% των τροχιών δημιουργήθηκαν λαμβάνοντας ενέργειες βάσει ενός pd ελεγκτή. Σε αυτή την περίπτωση τα επεισόδια δεν αποτύγχαναν ποτέ και η διάρκειά τους ήταν τα προκαθορισμένα μέγιστα βήματα δημιουργίας τροχιάς που θέτονταν στον αλγόριθμο δημιουργίας τροχιάς. Το υπόλοιπο ποσοστό των τροχιών έγινε λαμβάνοντας εντελώς τυχαία και ισοπίθανα μία απο τις δύο πιθανές ενέργειες.



Figure 2: Φαίνεται η σχεδόν κατ'ολοκλήρου τυχαία, ισοπίθανη επιλογή ενεργειών κατά την διάρκεια δημιουργίας των transitions

Αυτό είχε ως αποτέλεσμα την δημιουργία πιο σύντομων επεισοδίων αλλά και την εξερεύνηση περισσότερων περιοχών του χώρου κατάστασης λόγω της τυχαιότητας, γεγονός που με τον pd ελεγκτή ήταν αδύνατο καθώς επέβαλε σχεδόν αμέσως την ισορροπία στο σύστημα και την διατήρηση αυτής σε μια μικρή περιοχή.

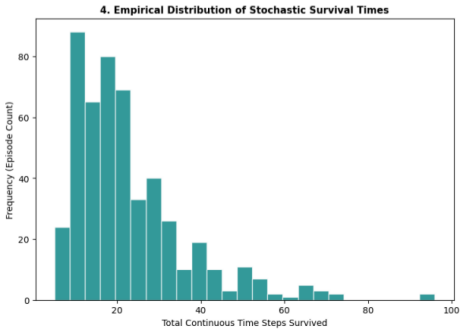
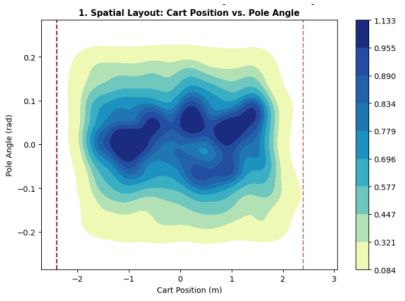
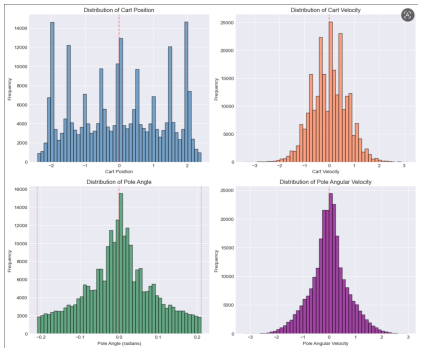


Figure 3: Οι περισσότερες τροχιές όπως είναι αναμενόμενο είναι σύντομες με λίγες (αυτές που δημιουργήθηκαν με την χρήση του pd ελεγκτή) να επιβιώνουν για μεγάλο αριθμό χρονικών βημάτων

Έτσι συλλέχτηκε ένας μεγάλος αριθμός από τροχιές πάνω στις οποίες εκπαιδεύτηκαν τα μοντέλα που θα παρουσιαστούν παρακάτω. Για την δοκιμή και αξιολόγηση των μοντέλων σε δεδομένα test/validation χρησιμοποιήθηκαν τροχιές που τα μοντέλα δεν "είδαν" κατά την εκπαίδευση



(a) Ικανοποιητική κάλυψη του χώρου καταστάσεων



(b) Φαίνεται η χρήση διαφορετικών αρχικών καταστάσεων καθώς και η τάση να διατηρηθεί η γωνία στα επιθυμητά όρια.

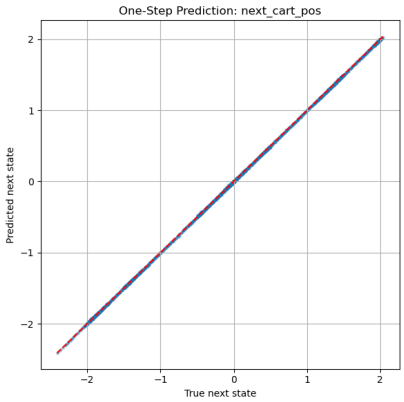
Τέλος επειδή παρατηρήθηκε διαφορά μιας τάξης μεγέθους στην γωνία της ράβδου σε σχέση με τις άλλες συνισταμένες του διανύσματος κατάστασης πραγματοποιήθηκε standardization. Η τεχνική αυτή χρησιμοποιήθηκε για την αποφυγή δυσανάλογης κυριαρχίας κάποιων συνιστωσών και την αποτροπή πιθανής αργής σύγκλισης ή αστάθειας κατά την διαδικασία της εκπαίδευσης.

4. Μοντέλα πρόβλεψης

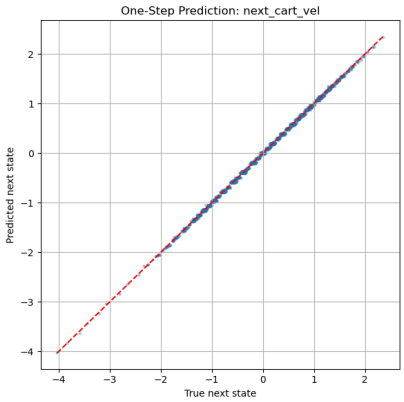
4.1 Ντετερμινιστικό μοντέλο πρόβλεψης ενός βήματος

Αρχικά αναπτύχθηκε ένα απλό μοντέλο το οποίο δίνοντάς του μια αρχική κατάσταση και μία ενέργεια καλούνταν να προβλέψει την επόμενη κατάσταση. Παρατηρήθηκε ότι με σχετικά απλές αρχιτεκτονικές που αποτελούνταν από την είσοδο και 2 hidden layers προέκυπταν αρκετά αξιόπιστες προβλέψεις της κατάστασης στην οποία θα βρεθεί το σύστημα του CartPole. Επίσης σαν κριτήριο σύγκλισης στην πραγματική επόμενη κατάσταση χρησιμοποιήθηκε το Mean Squared Error μεταξύ της πραγματικής και της προβλεπόμενης κατάστασης που κατέληγε το μοντέλο. Τέλος για optimizer έγινε χρήση του Adam.

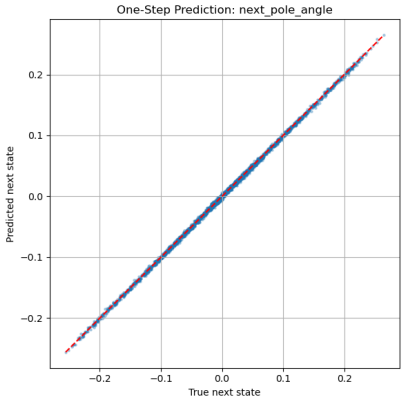
4.1.1 Αποτελέσματα ντετερμινιστικής πρόβλεψη ενός βήματος



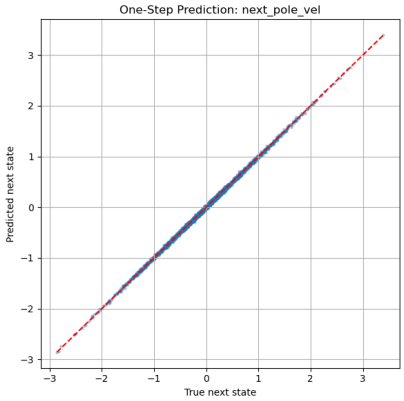
(a) Cart position



(b) Cart velocity



(c) Pole angle



(d) Pole angle velocity

Όπως είναι φανερό η πρόβλεψη της επόμενης κατάστασης γίνεται αρκετά αξιόπιστα καθώς βλέπουμε πολύ καλό matching ανάμεσα των επόμενων καταστάσεων και αυτών που πρόβλεψε το μοντέλο. Παρακάτω φαίνεται και το RMSE για κάθε συνιστώσα του διανύσματος κατάστασης.

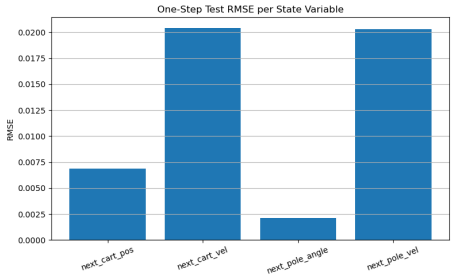


Figure 6: Root Mean Squared Error of each state component

4.2 Ντετερμινιστικό μοντέλο πρόβλεψης πολλαπλών βημάτων

Σε αυτό το στάδιο της εργασίας στόχος είναι να επιτευχθεί ικανοποιητική πρόβλεψη πολλαπλών επόμενων καταστάσεων μιας σειράς χρονικών βημάτων του συστήματος. Η πρώτη και πιο απλή προσέγγιση ήταν η χρήση του μοντέλου που αναπτύχθηκε προηγουμένως αλλά κάθε φορά για την πρόβλεψη της επόμενης κατάστασης να δέχεται σαν είσοδο την προηγούμενη κατάσταση που πρόβλεψε και την αντίστοιχη ενέργειά της. Η διαδικασία αυτή γινόταν επαναληπτικά μέχρι το πέρας του καθορισμένου χρονικού ορίζοντα. Η λογική αυτή περιγράφεται από την παρακάτω σχέση:

$$\hat{\mathbf{x}}_{t+k} = f_\theta\left(\hat{\mathbf{x}}_{t+k-1}, a_{t+k-1}\right), \qquad k = 1, \ldots, H.$$

4.2.1 Αποτελέσματα ντετερμινιστικής πρόβλεψης πολλαπλών βημάτων

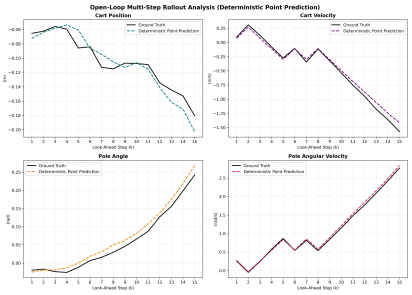
Η ανάλυση των αποτελεσμάτων του ντετερμινιστικού μοντέλου (MLP δύο επιπέδων με 64 νευρώνες) καταδεικνύει ότι η ικανότητα πρόβλεψης δεν είναι ομοιόμορφη σε όλο το εύρος του χώρου καταστάσεων. Παρότι η αρχιτεκτονική του μοντέλου είναι επαρκώς ισχυρή για να αναπαραστήσει τις κινηματικές εξισώσεις του CartPole, η ακρίβεια παρακολούθησης (tracking MSE) παρουσιάζει σημαντικές διακυμάνσεις ανάλογα με την τροχιά.

Παρατηρείται ότι το μοντέλο διατηρεί εξαιρετική ακρίβεια σε περιοχές του χώρου καταστάσεων όπου η πυκνότητα των δεδομένων εκπαίδευσης είναι υψηλή και οι κλίσεις της δυναμικής είναι ήπιες. Αντίθετα, η υποβάθμιση της πρόβλεψης γίνεται έντονη όταν το σύστημα οδηγείται σε περιοχές *Out-of-Distribution (OOD)*, όπου έχουμε:

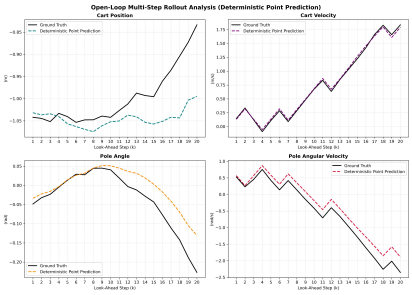
1. **Περιορισμένη Πυκνότητα Δεδομένων:** Σε περιοχές του χώρου καταστάσεων με περιορισμένα δείγματα εκπαίδευσης, το μοντέλο αποτυγχάνει να γενικεύσει σωστά τη δυναμική συμπεριφορά, με αποτέλεσμα οι συσσωρευμένες προβλέψεις να αποκλίνουν από την πραγματική τροχιά.

2. **Προσέγγιση Φυσικών Ορίων:** Καθώς το σύστημα πλησιάζει τα φυσικά όρια λειτουργίας του (π.χ. μεγάλες γωνίες κλίσης της ράβδου ή οριακές θέσεις του αμαξιδίου), οι μη γραμμικότητες της δυναμικής εντείνονται. Σε αυτά τα σημεία, η ντετερμινιστική πρόβλεψη, στερούμενη μηχανισμού εκτίμησης της αβεβαιότητας, αδυνατεί να διαχειριστεί την αυξημένη ευαισθησία του συστήματος στις αρχικές συνθήκες, οδηγώντας σε ταχεία μεγέθυνση του σφάλματος.

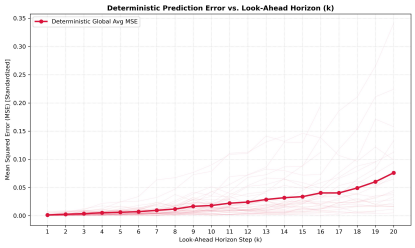
Συνεπώς, το σφάλμα παρακολούθησης που παρατηρείται σε μακροπρόθεσμους ορίζοντες δεν αποτελεί *a priori* αδυναμία του δικτύου να μοντελοποιήσει το σύστημα, αλλά συνέπεια της τοπικής έλλειψης πληροφορίας και της αδυναμίας του ντετερμινιστικού μοντέλου να αναγνωρίσει τα όρια της δικής του αξιοπιστίας κατά την αναδρομική διάδοση των προβλέψεων. Παρακάτω παρουσιάζονται δυο παραδείγματα της λειτουργίας του μοντέλου για τυχαία τροχιά από το test set .



(a) Small Compounding Error in Cart Position Tracking



(b) Large Compounding Error in Cart Position Tracking



(c) error as a function of the prediction horizon

4.3 Πιθανοτικό μοντέλο πρόβλεψης επόμενης κατάστασης με αβεβαιότητα

Σκοπός του πιθανοτικού μοντέλου είναι η πρόβλεψη της επόμενης κατάστασης του συστήματος CartPole, λαμβάνοντας υπόψη όχι μόνο τη μέση αναμενόμενη τιμή της πρόβλεψης, αλλά και την αβεβαιότητα που τη συνοδεύει. Σε αντίθεση με το απλό ντετερμινιστικό μοντέλο, το οποίο επιστρέφει μία μοναδική πρόβλεψη για την επόμενη κατάσταση, το πιθανοτικό μοντέλο επιστρέφει μία κατανομή πιθανότητας για την επό-

μενη κατάσταση.

Συγκεκριμένα, γίνεται προσπάθεια προσέγγισης της υπό συνθήκη κατανομής:

$$p(\mathbf{x}_{t+1} \mid \mathbf{x}_t, a_t)$$

και το μοντέλο επιστρέφει δύο εξόδους:

$$\boldsymbol{\mu}_{t+1}, \quad \boldsymbol{\sigma}^2_{t+1},$$

δηλαδή τη μέση προβλεπόμενη επόμενη κατάσταση και τη διακύμανση για κάθε συνιστώσα του διανύσματος κατάστασης.

Η είσοδος του μοντέλου αποτελείται από την τρέχουσα κατάσταση $\mathbf{x}_t$ και τη διακριτή ενέργεια a_t. Επειδή η ενέργεια λαμβάνει διακριτές τιμές, πρώτα μετατρέπεται σε συνεχές διάνυσμα μέσω ενός επιπέδου embedding. Στη συνέχεια, το embedding της ενέργειας ενώνεται με το διάνυσμα της κατάστασης και σχηματίζει το ενιαίο διάνυσμα εισόδου, το οποίο περνά από ένα κοινό νευρωνικό δίκτυο κορμού (*shared backbone*).

Η αρχιτεκτονική του μοντέλου αποτελείται από δύο πλήρως συνδεδεμένα επίπεδα με 64 νευρώνες και συνάρτηση ενεργοποίησης ReLU. Επιπλέον, χρησιμοποιείται Dropout με πιθανότητα $p = 0.2$, ώστε να περιοριστεί η υπερπροσαρμογή και να βελτιωθεί η δυνατότητα γενίκευσης του μοντέλου. Μετά το κοινό τμήμα του δικτύου, η αρχιτεκτονική χωρίζεται σε δύο κεφαλές εξόδου. Η πρώτη κεφαλή προβλέπει τη μέση τιμή $\boldsymbol{\mu}_{t+1}$, ενώ η δεύτερη προβλέπει τη λογαριθμική διακύμανση $\log \boldsymbol{\sigma}^2_{t+1}$.

Η πρόβλεψη της διακύμανσης γίνεται σε λογαριθμική κλίμακα για λόγους αριθμητικής σταθερότητας. Στη συνέχεια, οι τιμές της λογαριθμικής διακύμανσης περιορίζονται στο διάστημα $[-8, 4]$, ώστε να αποφεύγονται υπερβολικά μικρές ή υπερβολικά μεγάλες τιμές. Τέλος, μετά από εκθετικοποίηση λαμβάνεται η τιμή της διακύμανσης:

$$\boldsymbol{\sigma}^2_{t+1} = \exp\left(\log \boldsymbol{\sigma}^2_{t+1}\right).$$

Συνολικά, η λειτουργία του μοντέλου περιγράφεται ως:

$$(\boldsymbol{\mu}_{t+1}, \boldsymbol{\sigma}^2_{t+1}) = f_\theta(\mathbf{x}_t, a_t).$$

Η αρχικοποίηση των βαρών των γραμμικών επιπέδων γίνεται με χρήση της μεθόδου Xavier, ενώ τα biases αρχικοποιούνται στο μηδέν. Οι επιλογές αυτές συμβάλλουν στη σταθερότητα κατά τη διάρκεια της εκπαίδευσης του δικτύου και στη βελτίωση της συμπεριφοράς του κατά την πρόβλεψη.

4.4 Ensemble Νευρωνικό Δίκτυο πρόβλεψης επόμενης κατάστασης

Με στόχο τη βελτίωση της αξιοπιστίας των προβλέψεων και την εκτίμηση τόσο της αλεατορικής όσο και της επιστημικής αβεβαιότητας, υλοποιήθηκε μία αρχιτεκτονική

Deep Ensemble. Η βασική ιδέα των ensemble μοντέλων είναι ότι, αντί να χρησιμοποιείται ένα μόνο νευρωνικό δίκτυο για την πραγματοποίηση των προβλέψεων, χρησιμοποιούνται πολλαπλά ανεξάρτητα μοντέλα τα οποία εκπαιδεύονται ξεχωριστά. Κατά τη διαδικασία πρόβλεψης, κάθε μοντέλο παράγει τη δική του εκτίμηση για τη μέση τιμή και τη διακύμανση της επόμενης κατάστασης. Οι επιμέρους προβλέψεις συνδυάζονται στη συνέχεια ώστε να παραχθεί μία κοινή πρόβλεψη μεγαλύτερης αξιοπιστίας.

Η συγκεκριμένη προσέγγιση επιτρέπει την ταυτόχρονη εκτίμηση δύο διαφορετικών μορφών αβεβαιότητας. Η πρώτη είναι η **Aleatoric Uncertainty**, η οποία εκφράζει τη στοχαστικότητα που είναι εγγενής στο ίδιο το σύστημα, ενώ η δεύτερη είναι η **Epistemic Uncertainty**, η οποία οφείλεται στην αβεβαιότητα του ίδιου του μοντέλου και εκτιμάται μέσω της διαφωνίας μεταξύ των επιμέρους νευρωνικών δικτύων. Όσο μεγαλύτερη είναι η απόκλιση μεταξύ των προβλέψεων των μοντέλων, τόσο μεγαλύτερη θεωρείται η αβεβαιότητα του ensemble σχετικά με τη συγκεκριμένη περιοχή του χώρου καταστάσεων.

Η αρχιτεκτονική που χρησιμοποιήθηκε αποτελείται από πέντε ανεξάρτητα πιθανοτικά νευρωνικά δίκτυα, τα οποία έχουν ακριβώς την ίδια δομή με το πιθανοτικό μοντέλο ενός βήματος που παρουσιάστηκε στην προηγούμενη ενότητα. Κάθε δίκτυο διαθέτει ανεξάρτητες παραμέτρους και εκπαιδεύεται αυτόνομα, με αποτέλεσμα κάθε μέλος του ensemble να προσεγγίζει ελαφρώς διαφορετικά τη δυναμική του συστήματος. Για κάθε είσοδο $(\mathbf{x}_t, a_t)$, το κάθε μοντέλο επιστρέφει τη μέση προβλεπόμενη κατάσταση $\boldsymbol{\mu}_i$ και την αντίστοιχη διακύμανση $\boldsymbol{\sigma}_i^2$.

Η τελική μέση πρόβλεψη του ensemble υπολογίζεται ως ο μέσος όρος των επιμέρους προβλέψεων:

$$\boldsymbol{\mu}_{ens} = \frac{1}{M} \sum_{i=1}^{M} \boldsymbol{\mu}_i,$$

όπου M είναι το πλήθος των μοντέλων του ensemble.
Η συνολική διακύμανση υπολογίζεται σύμφωνα με τον Νόμο της Ολικής Διακύμανσης (*Law of Total Variance*), συνδυάζοντας τη μέση προβλεπόμενη διακύμανση των επιμέρους μοντέλων με τη διασπορά των μέσων προβλέψεών τους:

$$\boldsymbol{\sigma}_{ens}^2 = \frac{1}{M} \sum_{i=1}^{M} \boldsymbol{\sigma}_i^2 + \mathrm{Var}(\boldsymbol{\mu}_i).$$

Με τον τρόπο αυτό, η τελική διακύμανση περιλαμβάνει τόσο την αλεατορική αβεβαιότητα όσο και την επιστημική αβεβαιότητα, παρέχοντας μία πιο ολοκληρωμένη και αξιόπιστη εκτίμηση της εμπιστοσύνης του μοντέλου στις προβλέψεις του.

5. Μέθοδοι Διάδοσης Αβεβαιότητας σε Πολυβηματικές Προβλέψεις

Στις προβλέψεις ενός χρονικού βήματος η εκτιμώμενη αβεβαιότητα αφορά αποκλειστικά την επόμενη κατάσταση του συστήματος. Αντίθετα, στις πολυβηματικές προβλέψεις (multi-step rollouts) η αβεβαιότητα μεταβάλλεται δυναμικά, καθώς κάθε νέα πρόβλεψη βασίζεται στην προηγούμενη εκτιμώμενη κατάσταση. Ως αποτέλεσμα, τα σφάλματα και η αβεβαιότητα δεν παραμένουν σταθερά αλλά διαδίδονται και συσσωρεύονται όσο αυξάνεται ο χρονικός ορίζοντας πρόβλεψης.

Για τον λόγο αυτό δεν αρκεί η εκτίμηση της αβεβαιότητας σε ένα μόνο χρονικό βήμα. Απαιτείται μία κατάλληλη μέθοδος διάδοσης της αβεβαιότητας (*uncertainty propagation*), η οποία να υπολογίζει τον τρόπο με τον οποίο η κατανομή πιθανότητας της κατάστασης εξελίσσεται κατά τη διάρκεια του πολυβηματικού rollout. Η διαδικασία αυτή επιτρέπει την εκτίμηση τόσο της αναμενόμενης μελλοντικής κατάστασης όσο και της αξιοπιστίας κάθε πρόβλεψης κατά μήκος του χρονικού ορίζοντα.

Στην παρούσα εργασία εξετάζονται τρεις διαφορετικές τεχνικές διάδοσης της αβεβαιότητας, οι οποίες διαφέρουν ως προς τον τρόπο με τον οποίο μεταφέρουν την πληροφορία της αβεβαιότητας από το ένα χρονικό βήμα στο επόμενο. Αρχικά παρουσιάζεται η μέθοδος *Deterministic Mean*, η οποία χρησιμοποιεί αποκλειστικά τη μέση προβλεπόμενη κατάσταση ως είσοδο στο επόμενο βήμα. Στη συνέχεια παρουσιάζεται η μέθοδος *Monte Carlo Propagation*, η οποία βασίζεται στη δειγματοληψία πολλαπλών πιθανών τροχιών, και τέλος η μέθοδος *Moment Matching*, η οποία διαδίδει αναλυτικά τη μέση τιμή και τη συνδιακύμανση μέσω γραμμικοποίησης της δυναμικής του μοντέλου. Οι τρεις αυτές προσεγγίσεις συγκρίνονται στη συνέχεια ως προς την ακρίβεια πρόβλεψης, την ποιότητα της εκτίμησης της αβεβαιότητας και το υπολογιστικό τους κόστος.

5.1 Deterministic Mean Propagation

Η μέθοδος *Deterministic Mean Propagation* αποτελεί την απλούστερη τεχνική πολυβηματικής πρόβλεψης και χρησιμοποιείται ως σημείο αναφοράς για τις υπόλοιπες μεθόδους διάδοσης της αβεβαιότητας. Η βασική της ιδέα είναι ότι σε κάθε χρονικό βήμα χρησιμοποιείται αποκλειστικά η μέση προβλεπόμενη κατάσταση ως είσοδος για την επόμενη πρόβλεψη, χωρίς να λαμβάνεται υπόψη η αβεβαιότητα που συνοδεύει την εκτίμηση.

Δεδομένης της αρχικής κατάστασης $\mathbf{x}_t$ και της ακολουθίας ενεργειών, το μοντέλο παράγει αναδρομικά τις μελλοντικές καταστάσεις σύμφωνα με τη σχέση

$$\hat{\mathbf{x}}_{t+k} = f_\theta\left(\hat{\mathbf{x}}_{t+k-1}, a_{t+k-1}\right), \qquad k = 1, \ldots, H.$$

Σε κάθε χρονικό βήμα διατηρείται μόνο η μέση πρόβλεψη $\boldsymbol{\mu}$, η οποία χρησιμοποιείται ως είσοδος στο επόμενο βήμα του rollout. Η εκτιμώμενη διακύμανση δεν συμμετέχει

στη διαδικασία της αναδρομής και επομένως δεν επηρεάζει την εξέλιξη των επόμενων προβλέψεων.

Το βασικό πλεονέκτημα της μεθόδου είναι η ιδιαίτερα μικρή υπολογιστική της πολυπλοκότητα, καθώς απαιτεί ένα μόνο forward pass του νευρωνικού δικτύου σε κάθε χρονικό βήμα. Ωστόσο, η αγνόηση της αβεβαιότητας έχει ως αποτέλεσμα τη συσσώρευση των σφαλμάτων πρόβλεψης όσο αυξάνεται ο χρονικός ορίζοντας, οδηγώντας συχνά σε υπερβολική εμπιστοσύνη στις μακροπρόθεσμες προβλέψεις.

5.2 Monte Carlo Propagation

Η μέθοδος *Monte Carlo Propagation* διαδίδει την αβεβαιότητα μέσω δειγματοληψίας από την κατανομή πιθανότητας που προβλέπει το μοντέλο σε κάθε χρονικό βήμα. Σε αντίθεση με τη μέθοδο *Deterministic Mean Propagation*, όπου μόνο η μέση προβλεπόμενη κατάσταση χρησιμοποιείται ως είσοδος στο επόμενο βήμα, η μέθοδος Monte Carlo διατηρεί πολλαπλές πιθανές εξελίξεις του συστήματος, επιτρέποντας την προσομοίωση διαφορετικών πιθανών τροχιών.

Αρχικά δημιουργείται ένα σύνολο από N σωματίδια (particles), τα οποία αρχικοποιούνται όλα στην ίδια αρχική κατάσταση. Στην παρούσα εργασία χρησιμοποιήθηκαν $N = 100$ σωματίδια. Για κάθε χρονικό βήμα, το πιθανοτικό μοντέλο υπολογίζει για κάθε σωματίδιο τη μέση τιμή $\boldsymbol{\mu}$ και τη διακύμανση $\boldsymbol{\sigma}^2$ της επόμενης κατάστασης. Στη συνέχεια, για κάθε σωματίδιο πραγματοποιείται δειγματοληψία από την αντίστοιχη Γκαουσιανή κατανομή,

$$\mathbf{x}_{t+1}^{(i)} = \boldsymbol{\mu}_{t+1}^{(i)} + \sqrt{\boldsymbol{\sigma}_{t+1}^{2(i)}}\, \boldsymbol{\epsilon}^{(i)},$$

όπου

$$\boldsymbol{\epsilon}^{(i)} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}).$$

Οι νέες καταστάσεις που προκύπτουν χρησιμοποιούνται ως είσοδοι στο επόμενο χρονικό βήμα, με αποτέλεσμα κάθε σωματίδιο να ακολουθεί μία διαφορετική πιθανή τροχιά του συστήματος. Μετά την ολοκλήρωση κάθε βήματος, η μέση προβλεπόμενη κατάσταση και η συνολική διακύμανση υπολογίζονται από το σύνολο των σωματιδίων.

Η συνολική διακύμανση προκύπτει από τον Νόμο της Ολικής Διακύμανσης, συνδυάζοντας τη μέση προβλεπόμενη αλεατορική αβεβαιότητα με τη διασπορά των σωματιδίων:

$$\boldsymbol{\sigma}_{\text{total}}^2 = E\left[\boldsymbol{\sigma}^2\right] + \text{Var}(\boldsymbol{\mu}).$$

Η μέθοδος Monte Carlo μπορεί να προσεγγίσει αποτελεσματικά ακόμη και ιδιαίτερα μη γραμμικές ή μη Γκαουσιανές κατανομές, καθώς δεν πραγματοποιεί καμία παραδοχή σχετικά με τη μορφή της κατανομής κατά τη διάδοση. Ωστόσο, η προσομοίωση μεγάλου αριθμού σωματιδίων αυξάνει σημαντικά το υπολογιστικό κόστος, καθώς απαιτεί την εκτέλεση πολλών forward passes του νευρωνικού δικτύου σε κάθε χρονικό βήμα του rollout.

5.3 Moment Matching

Η μέθοδος *Moment Matching* αποτελεί μία αναλυτική προσέγγιση διάδοσης της αβεβαιότητας, η οποία αποφεύγει τη χρήση δειγματοληψίας. Αντί να προσομοιώνει μεγάλο αριθμό πιθανών τροχιών, όπως η μέθοδος Monte Carlo, διαδίδει απευθείας τη μέση τιμή και τη συνδιακύμανση της κατανομής κατάστασης από το ένα χρονικό βήμα στο επόμενο.

Σε κάθε χρονικό βήμα, το πιθανοτικό μοντέλο προβλέπει τη μέση κατάσταση $\boldsymbol{\mu}$ και τη διακύμανση $\boldsymbol{\sigma}^2$. Παράλληλα, υπολογίζεται ο Ιακωβιανός πίνακας (Jacobian) του μοντέλου ως προς την είσοδο, ο οποίος περιγράφει την τοπική ευαισθησία της δυναμικής του συστήματος. Ο πίνακας αυτός χρησιμοποιείται για τη διάδοση της συνδιακύμανσης μέσω γραμμικοποίησης πρώτης τάξης της μη γραμμικής συνάρτησης μετάβασης.

Η συνδιακύμανση ενημερώνεται σύμφωνα με τη σχέση

$$\Sigma_{k+1} = J_k \Sigma_k J_k^T + \text{diag}(\sigma_k^2).$$

όπου $\mathbf{J}_k$ είναι ο Jacobian του μοντέλου στο χρονικό βήμα k, ενώ $\text{diag}(\boldsymbol{\sigma}_k^2)$ εκφράζει τη συνεισφορά της αλεατορικής αβεβαιότητας που προβλέπει το νευρωνικό δίκτυο.

Η μέση κατάσταση διαδίδεται αναδρομικά όπως και στις προηγούμενες μεθόδους, ενώ η διαγώνιος της μήτρας συνδιακύμανσης αποτελεί την προβλεπόμενη διακύμανση για κάθε μεταβλητή κατάστασης.

Βασικό πλεονέκτημα της μεθόδου είναι ότι παρέχει μία αναλυτική εκτίμηση της εξέλιξης της αβεβαιότητας χωρίς να απαιτείται μεγάλος αριθμός δειγμάτων, με αποτέλεσμα να είναι σημαντικά αποδοτικότερη υπολογιστικά από τη μέθοδο Monte Carlo. Ωστόσο, η ακρίβειά της βασίζεται στην παραδοχή ότι η μη γραμμική δυναμική του συστήματος μπορεί να προσεγγιστεί ικανοποιητικά μέσω γραμμικοποίησης πρώτης τάξης γύρω από τη μέση προβλεπόμενη κατάσταση.

6. Συγκριτική Αξιολόγηση των Μεθόδων Διάδοσης της Αβεβαιότητας

Η ποιοτική και ποσοτική αξιολόγηση των μεθόδων διάδοσης αβεβαιότητας — Deterministic Mean Propagation, Monte Carlo Propagation ($N = 100$) και Αναλυτικού Moment Matching — πραγματοποιήθηκε με βάση τα αποτελέσματα της Τροχιάς 24 (μήκος χρονικού ορίζοντα $H = 20$) και τις καθολικές κατανομές σφαλμάτων των γραφημάτων Totality. Η σύγκριση αναδεικνύει τις θεμελιώδεις διαφορές μεταξύ των προσεγγίσεων ως προς την ακρίβεια, τη βαθμονόμηση και τη συμπεριφορά τους ανάλογα με την ποιότητα του υποκείμενου προγνωστικού μοντέλου (Single-NN έναντι Deep Ensemble).

6.1 Ανάλυση Σφάλματος Πρόβλεψης και Συσσώρευσης Ολίσθησης

Η αναδρομική, open-loop τροφοδότηση των προβλέψεων προκαλεί μονοτονική αύξηση του σφάλματος παρακολούθησης (MSE) σε όλες τις μεθόδους λόγω του φαινομένου compounding error. Ωστόσο, η φύση της διάδοσης διαφοροποιεί τα αποτελέσματα:

- **Deterministic Mean & Moment Matching:** Στις μεθόδους αυτές, η διάδοση της κεντρικής τροχιάς ταυτίζεται, καθώς και οι δύο βασίζονται στην αναδρομική προώθηση της αναμενόμενης τιμής μ_t. Στο Single-NN το σφάλμα στο βήμα $k = 20$ εκτινάσσεται στο 0.320871, ενώ στο Deep Ensemble περιορίζεται εντυπωσιακά στο 0.183663 λόγω της εξάλειψης των τοπικών σφαλμάτων προσέγγισης από τη διαδικασία λήψης απόφασης συναίνεσης (consensus).
- **Monte Carlo Propagation:** Εισάγει στοχαστικότητα σε κάθε βήμα μέσω δειγματοληψίας σωματιδίων. Στην περίπτωση του Single-NN, η δειγματοληψία πολλαπλών σωματιδίων λειτουργεί ευεργετικά, εξομαλύνοντας τις ακραίες αποκλίσεις μέσω του μέσου όρου τους και επιτυγχάνοντας ελαφρώς χαμηλότερο τελικό σφάλμα (0.315431). Αντίθετα, στο Deep Ensemble, η στοχαστική δειγματοληψία εισάγει πρόσθετη τεχνητή διασπορά σε ένα ήδη βελτιστοποιημένο μέσο μονοπάτι, οδηγώντας σε ελαφρώς υψηλότερο τελικό σφάλμα (0.190223) σε σχέση με την αναλυτική μέση διαδρομή.

6.2 Δυναμική Εξέλιξη και Επέκταση της Προβλεπόμενης Διακύμανσης

Επειδή όπως αναφέρθηκε νωρίτερα στην ανάλυση της ντερμινιστικής προσέγγισης η συσσώρευση σφάλματος κατά μήκος του χρονικού ορίζοντα δε μπορεί να γενικευθεί όσον αφορά τη συμπεριφορά της, αλλά μεταβάλλεται σημαντικά από τροχιά σε τροχιά, η συμπεριφορά της προβλεπόμενης αβεβαιότητας (σ^2) αποτελεί το βασικότερο σημείο διαφοροποίησης των μεθόδων, όπως αποτυπώνεται στα γραφήματα Totality:

- **Deterministic Mean Propagation (Global Flat):** Όπως τεκμηριώνεται στα γραφήματα `TOTALITY`, η μέθοδος αυτή αποτυγχάνει πλήρως να διαδώσει την αβεβαιότητα, διατηρώντας τη διακύμανση τεχνητά στάσιμη (ή και μειούμενη) γύρω από την αρχική τιμή θορύβου.

- **Monte Carlo vs. Moment Matching (Global Expanding):** Και οι δύο πιθανοτικές μέθοδοι επιτυγχάνουν τη φυσική, μονοτονική επέκταση της διακύμανσης, αποτυπώνοντας την αυξανόμενη αβεβαιότητα του ορίζοντα. Η μέθοδος *Moment Matching* παρέχει μια πιο αναλυτική και συνεπή αύξηση, καθώς μεταφέρει την αβεβαιότητα μέσω του Ιακωβιανού πίνακα της δυναμικής του συστήματος. Η μέθοδος *Monte Carlo* ακολουθεί στενά την ίδια αυξητική, εμφανίζοντας ωστόσο στοχαστικό θόρυβο λόγω της δειγματοληψίας των πεπερασμένων σωματιδίων (N=100).

6.3 Στατιστική Βαθμονόμηση (Calibration) και Αξιοπιστία

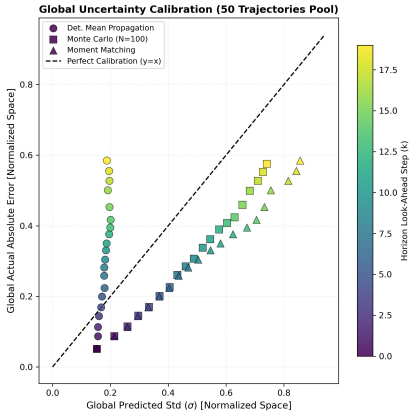
Η σύγκριση μεταξύ του πραγματικού σφάλματος και της προβλεπόμενης αβεβαιότητας (Calibration) αναδεικνύει την ανωτερότητα των πιθανοτικών μεθόδων όταν συνδυάζονται με το Deep Ensemble:

- Η *Deterministic Mean* πάσχει από ακραία υπερβολική αυτοπεποίθηση (overconfidence), καθώς το σφάλμα αυξάνεται εκθετικά αλλά η διακύμανση παραμένει στάσιμη, καθιστώντας την τυφλή σε επικίνδυνες αποκλίσεις.
- Οι μέθοδοι *Monte Carlo* και *Moment Matching* επιτυγχάνουν εξαιρετική βαθμονόμηση στο γράφημα

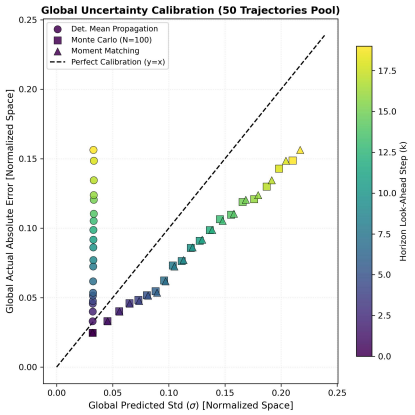
  (ιδιαίτερα μέχρι το βήμα $k = 13$), καθώς οι δείκτες ακολουθούν πιστά την ιδανική διαγώνιο $y = x$. Στα βαθύτερα βήματα, η Moment Matching αποδεικνύεται ελαφρώς πιο συντηρητική (conservative), υπερεκτιμώντας την αβεβαιότητα, γεγονός που την καθιστά ασφαλέστερη επιλογή για εφαρμογές robust ελέγχου.

Table 2: Συνοπτική Συγκριτική Αξιολόγηση Μεθόδων Διάδοσης Αβεβαιότητας (Τροχιά 250, $H = 20$)

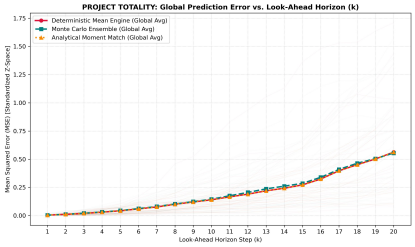
Χαρακτηριστικό / Μέθοδος	**Deterministic Mean**	**Monte Carlo (N=100)**	**Moment Matching**
MSE Σφάλμα (Single-NN)	0.320871	**0.315431**	0.320871
MSE Σφάλμα (Ensemble)	**0.183663**	0.190223	**0.183663**
Τελική Διακύμανση (Single-NN)	0.085059	0.562235	**0.720279**
Τελική Διακύμανση (Ensemble)	0.001289	0.056921	**0.055946**
Υπολογιστικό Κόστος	Ελάχιστο ($\mathcal{O}(1)$)	Μέγιστο ($\mathcal{O}(N)$)	Μεσαίο (Υπολογισμός Jacobian)
Χαρακτηρισμός Βαθμονόμησης	Overconfident	Ισορροπημένη/Εγκυρη	Στιβαρή / Συντηρητική



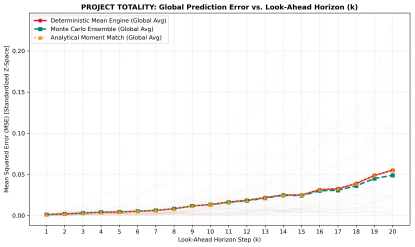
(a) Calibration between uncertainty and errors for single NN



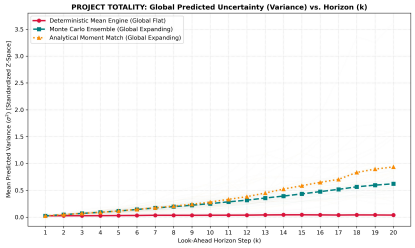
(b) Calibration between uncertainty and errors for ensemble NN



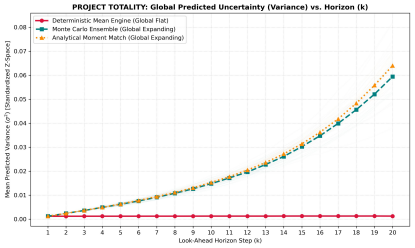
(c) Error vs horizon for single NN



(d) Error vs horizon for ensemble NN



(e) Variance vs time for single NN



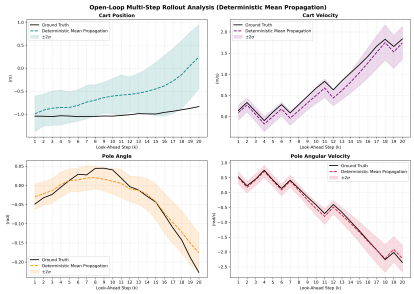
(f) Variance vs time for ensemble NN

6.4 Συμπεράσματα Σύγκρισης

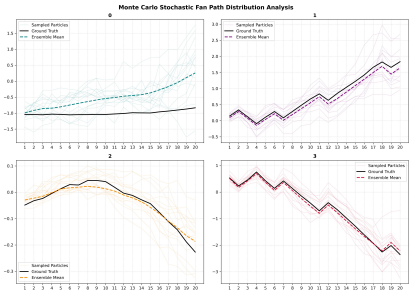
Η ανάλυση καταδεικνύει ότι η επιλογή της μεθόδου διάδοσης είναι άρρηκτα συνδεδεμένη με το υπολογιστικό budget και τις απαιτήσεις ασφαλείας του συστήματος. Η *Deterministic Mean Propagation* είναι κατάλληλη μόνο για πολύ βραχυπρόθεσμούς ορίζοντες λόγω της τυφλότητάς της στην αβεβαιότητα. Η *Monte Carlo* προσφέρει την πιο πιστή εμπειρική αναπαράσταση της κατανομής χωρίς γεωμετρικές παραδοχές, αλλά με υψηλό υπολογιστικό τίμημα. Η *Moment Matching* αναδεικνύεται ως η βέλτιστη επιλογή, προσφέροντας αναλυτική, μαθηματικά αυστηρή και συντηρητική διάδοση της αβεβαιότητας με ένα κλάσμα του υπολογιστικού κόστους της Monte Carlo.

6.5 Γραφικές παραστάσεις

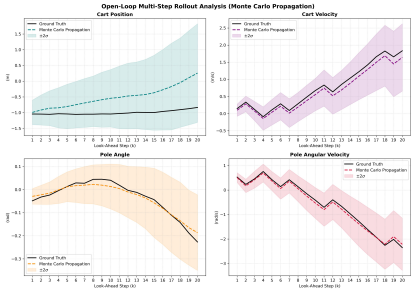
Single NN



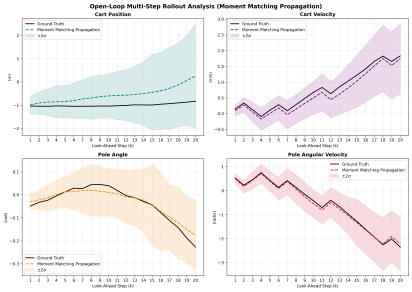
(a) Deterministic mean propagation



(b) Monte Carlo fan plot

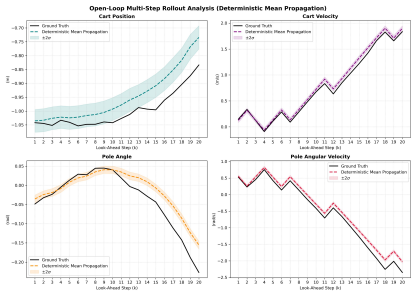


(c) Monte Carlo propagation

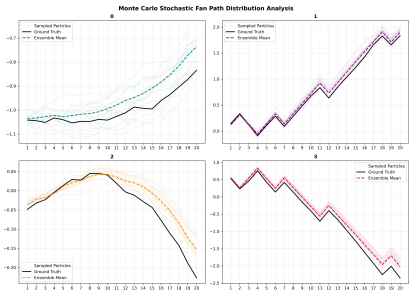


(d) Moment matching propagation

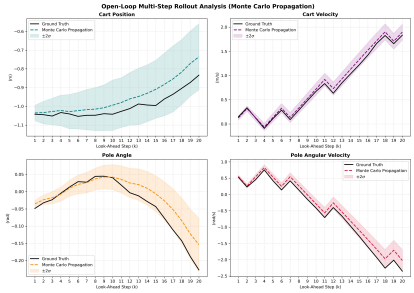
Ensemble NN



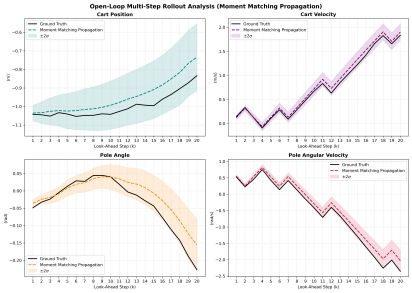
(a) Deterministic mean propagation



(b) Monte Carlo fan plot



(c) Monte Carlo propagation



(d) Moment matching propagation

Παρατήρηση επί της ομοιότητας των μεθόδων Monte Carlo και Moment Matching:
Από τη συγκριτική ανάλυση των γραφημάτων παρακολούθησης (trajectory plots) καθίσταται εμφανές ότι οι μέθοδοι *Monte Carlo Propagation* και *Moment Matching* παράγουν πρακτικά ταυτόσημες προβλέψεις, τόσο ως προς την κεντρική τροχιά (μ) όσο και ως προς τα όρια εμπιστοσύνης ($\pm 2\sigma$). Η συμπεριφορά αυτή είναι μαθηματικά απόλυτα δικαιολογημένη. Αφενός, το πλήθος των $N = 100$ σωματιδίων της μεθόδου Monte Carlo είναι στατιστικά επαρκές για να προσεγγίσει την πραγματική κατανομή στον χαμηλής διάστασης ($D = 4$) χώρο καταστάσεων του CartPole. Αφετέρου, η μέθοδος Moment Matching βασίζεται στη γραμμικοποίηση Taylor πρώτης τάξης (μέσω του Ιακωβιανού πίνακα) για τη διάδοση της συνδιακύμανσης. Εφόσον η δυναμική του CartPole στις περιοχές ισορροπίας είναι σχετικά ομαλή, το σφάλμα γραμμικοποίησης (linearization error) είναι αμελητέο. Ως εκ τούτου, η αναλυτική διάδοση (Moment Matching) και η στοχαστική εμπειρική διάδοση (Monte Carlo) ταυτίζονται, επιβεβαιώνοντας αμοιβαία την ορθότητα των δύο διαφορετικών μαθηματικών προσεγγίσεων, με τη Moment Matching ωστόσο να επιτυγχάνει το ίδιο αποτέλεσμα με δραματικά μικρότερο υπολογιστικό κόστος.

7. Συνολική Σύνθεση της Δυναμικής Διάδοσης της Αβεβαιότητας σε Προβλέψεις Μεγάλου Χρονικού Ορίζοντα

Μια αυστηρή αξιολόγηση της πολυβηματικής πρόβλεψης ανοικτού βρόχου (open-loop) αναδεικνύει τις θεμελιώδεις ισορροπίες μεταξύ της υπολογιστικής αποδοτικότητας, της υποβάθμισης της ικανότητας παρακολούθησης της δυναμικής του συστήματος και της στατιστικής βαθμονόμησης της αβεβαιότητας σε μεγάλους χρονικούς ορίζοντες.

7.1 Μηχανισμός Συσσώρευσης Σφαλμάτων στις Πολυβηματικές Προβλέψεις

Οι πολυβηματικές χρονικές προβλέψεις σε αυτόνομα δυναμικά συστήματα πραγματοποιούνται σε ένα αναδρομικό πλαίσιο ανοικτού βρόχου (*autoregressive open-loop*). Επειδή οι πραγματικές μετρήσεις αισθητήρων $\mathbf{x}_t$ δεν είναι διαθέσιμες κατά μήκος του χρονικού ορίζοντα πρόβλεψης, το μοντέλο βασίζεται αποκλειστικά στις δικές του εκτιμήσεις καταστάσεων ως είσοδο για τα επόμενα χρονικά βήματα:

$$\hat{\mathbf{x}}_{t+k} = f_\theta(\hat{\mathbf{x}}_{t+k-1}, \mathbf{a}_{t+k-1})$$

Η αναδρομική αυτή εξάρτηση οδηγεί σε μία **αλυσίδα συσσωρευόμενων σφαλμάτων (compounding error cascade)**. Οποιοδήποτε μικρό σφάλμα πρόβλεψης ή στοχαστική διαταραχή (aleatoric noise) στο πρώτο βήμα πρόβλεψης ($k = 1$) μεταβάλλει τις εισόδους του μοντέλου για το επόμενο βήμα ($k = 2$). Στο πρόβλημα του ανεστραμμένου εκκρεμούς (CartPole), οι μεταβλητές θέσης λειτουργούν ως ολοκληρωτές των ταχυτήτων. Κατά συνέπεια, ακόμη και μικρά σφάλματα στις προβλεπόμενες ταχύτητες συσσωρεύονται γρήγορα, οδηγώντας τις αναδρομικές εισόδους σε περιοχές του χώρου καταστάσεων που δεν έχουν παρατηρηθεί κατά την εκπαίδευση (Out-of-Distribution, OOD), όπου τα σφάλματα προσέγγισης της συνάρτησης αυξάνονται εκθετικά.

7.2 Επίδραση της Μοντελοποίησης της Αβεβαιότητας στις Μακροπρόθεσμες Προβλέψεις

Η μοντελοποίηση της αβεβαιότητας δεν μειώνει άμεσα το σημειακό σφάλμα παρακολούθησης (Mean Squared Error - MSE) της μέσης πρόβλεψης υπό μία προσέγγιση πρώτης τάξης. Ωστόσο, βελτιώνει ουσιαστικά τη στατιστική αξιοπιστία των προβλέψεων μεγάλου χρονικού ορίζοντα. Τα ντετερμινιστικά μοντέλα σημειακής πρόβλεψης στερούνται πληροφορίας σχετικά με την αβεβαιότητα της εκτίμησής τους και συχνά συγκλίνουν προς μέσες τιμές των δεδομένων εκπαίδευσης, παράγοντας προβλέψεις που δεν αντανακλούν επαρκώς την πραγματική δυναμική του συστήματος.

Με την εκτίμηση της αβεβαιότητας, το πρόβλημα μετατρέπεται από την πρόβλεψη ενός μοναδικού διανύσματος κατάστασης στη διάδοση ολόκληρης της κατανομής πιθανότητας

$$\mathcal{P}(\mathbf{x}_{t+k} \mid \mathbf{x}_t).$$

Η πληροφορία αυτή επιτρέπει στα συστήματα σχεδιασμού τροχιάς και στους αλγορίθμους Model Predictive Control (MPC) να λαμβάνουν αποφάσεις λαμβάνοντας υπόψη όχι μόνο την αναμενόμενη εξέλιξη του συστήματος αλλά και την αξιοπιστία των προβλέψεων, αποφεύγοντας έτσι καταστάσεις υπερβολικής εμπιστοσύνης (overconfidence).

7.3 Χρονική Εξέλιξη της Αβεβαιότητας του Συστήματος

Η αβεβαιότητα αυξάνεται μονοτονικά όσο μεγαλώνει ο χρονικός ορίζοντας πρόβλεψης σε δυναμικά συστήματα με ασταθή συμπεριφορά. Η συνολική διασπορά της πρόβλεψης σε κάθε χρονικό βήμα αποτελεί το αποτέλεσμα δύο διαφορετικών συνιστωσών:

- **Aleatoric Uncertainty:** Η μη αναγώγιμη, εξαρτώμενη από την είσοδο στοχαστική αβεβαιότητα που προέρχεται από τη φύση του ίδιου του συστήματος ή του περιβάλλοντος.
- **Epistemic / Trajectory Dispersion:** Η επιπλέον διασπορά που προκαλείται από τη γεωμετρική διάδοση των σφαλμάτων μέσω της δυναμικής του συστήματος.

Στην αναλυτική μέθοδο *Moment Matching*, η εξέλιξη της αβεβαιότητας περιγράφεται μέσω του Ιακωβιανού πίνακα της δυναμικής, σύμφωνα με την προσέγγιση πρώτης τάξης

$$\mathbf{J}\sigma\mathbf{J}^T + \sigma_{\text{aleatoric}}.$$

Αντίθετα, στη μη παραμετρική μέθοδο *Monte Carlo*, κάθε σωματίδιο (particle) ακολουθεί διαφορετική πιθανή εξέλιξη της δυναμικής του συστήματος, με αποτέλεσμα η εμπειρική διασπορά των δειγμάτων να αυξάνεται συνεχώς όσο μεγαλώνει ο χρονικός ορίζοντας πρόβλεψης.

7.4 Όρια Αξιοπιστίας του Προβλεπτικού Μοντέλου

Το μοντέλο παύει να αποτελεί αξιόπιστο εργαλείο πρόβλεψης όταν τα όρια εμπιστοσύνης της προβλεπόμενης αβεβαιότητας γίνουν συγκρίσιμα ή μεγαλύτερα από τα φυσικά όρια λειτουργίας του συστήματος.

Στην περίπτωση του CartPole, αυτό συμβαίνει όταν το διάστημα εμπιστοσύνης $\pm 2\sigma$ των προβλεπόμενων μεταβλητών επεκτείνεται πέρα από τα φυσικά όρια λειτουργίας του περιβάλλοντος, δηλαδή πέρα από τα όρια της τροχιάς του αμαξιδίου (± 2.4 μέτρα) ή πέρα από τη μέγιστη επιτρεπτή γωνία ισορροπίας της ράβδου. Από το σημείο αυτό και έπειτα, η πολυβηματική πρόβλεψη ανοικτού βρόχου παύει να είναι πρακτικά χρήσιμη, υποδεικνύοντας την ανάγκη για νέα μέτρηση από το πραγματικό σύστημα ή για ενεργοποίηση κάποιου μηχανισμού ασφαλούς ελέγχου.

7.5 Περιορισμοί των Μεθόδων που Βασίζονται σε Δειγματοληψία

Παρότι οι μη παραμετρικές μέθοδοι *Monte Carlo Ensemble* είναι ιδιαίτερα ισχυρές, καθώς μπορούν να διαδώσουν αυθαίρετες μη Γκαουσιανές κατανομές μέσα από μη

γραμμικά μοντέλα χωρίς να απαιτείται υπολογισμός παραγώγων, παρουσιάζουν δύο βασικούς περιορισμούς:

1. **Υπολογιστικό κόστος:** Η προσομοίωση μεγάλου αριθμού σωματιδίων (π.χ. $N = 100$) απαιτεί την εκτέλεση εκατοντάδων προωθητικών διελεύσεων (forward passes) του νευρωνικού δικτύου σε κάθε χρονικό βήμα πρόβλεψης. Η διαδικασία αυτή αυξάνει σημαντικά τις απαιτήσεις σε υπολογιστική ισχύ και μνήμη, καθιστώντας δύσκολη την εφαρμογή της σε συστήματα πραγματικού χρόνου υψηλής συχνότητας.

2. **Εξάρτηση από τον αριθμό των σωματιδίων και τη διάσταση του χώρου καταστάσεων:** Καθώς αυξάνεται η διάσταση του προβλήματος, απαιτείται εκθετικά μεγαλύτερος αριθμός σωματιδίων για την αξιόπιστη αναπαράσταση της κατανομής πιθανότητας. Μικρός αριθμός δειγμάτων οδηγεί σε μεγάλη στοχαστική διακύμανση και σε ασταθή όρια εμπιστοσύνης, τα οποία ενδέχεται να μην αποτυπώνουν επαρκώς την πραγματική αβεβαιότητα του συστήματος.