Multi-step Prediction with Uncertainty

Πρόβλεψη πολλαπλών βημάτων και διάδοση αβεβαιότητας στο CartPole

Στρατηγός--Αφράτης Νικόλαος
Τσικνάκης Εμμανουήλ
Τρύφων Αντώνιος
Στραβομύτης Βελισσάριος--Βησαρίων

23 Ιουνίου 2026

Τεχνητή Νοημοσύνη ΙΙ

Δομή παρουσίασης

1. Πρόβλημα και στόχος της εργασίας
2. Περιβάλλον CartPole και συλλογή δεδομένων
3. Μοντέλα πρόβλεψης ενός βήματος
4. Πολυβηματική πρόβλεψη και συσσώρευση σφάλματος
5. Μέθοδοι διάδοσης αβεβαιότητας
6. Πειραματικά αποτελέσματα και συμπεράσματα

Στόχος της εργασίας

Κεντρικό ερώτημα
Πώς μπορούμε να προβλέψουμε αξιόπιστα τη μελλοντική εξέλιξη ενός δυναμικού συστήματος, όταν το σφάλμα και η αβεβαιότητα αυξάνονται με τον χρονικό ορίζοντα;

- Μελέτη πολυβηματικής πρόβλεψης σε δυναμικό σύστημα.
- Εκτίμηση όχι μόνο της μέσης πρόβλεψης, αλλά και της αβεβαιότητας.
- Σύγκριση ντετερμινιστικών και πιθανοτικών προσεγγίσεων.
- Αξιολόγηση με βάση σφάλμα, διακύμανση, βαθμονόμηση και υπολογιστικό κόστος.

Δυναμικό σύστημα: CartPole-v1

- Χρησιμοποιήθηκε το περιβάλλον CartPole-v1 της βιβλιοθήκης Gymnasium.
- Ένα αμαξίδιο κινείται οριζόντια και πρέπει να ισορροπήσει μία ράβδο.
- Οι διαθέσιμες ενέργειες είναι:

$$a_t \in \{0, 1\}$$

όπου οι τιμές αντιστοιχούν σε δύναμη προς τα αριστερά ή προς τα δεξιά.

Διάνυσμα κατάστασης

$$\mathbf{x}_t = \begin{bmatrix} x_t \\ \dot{x}_t \\ \theta_t \\ \dot{\theta}_t \end{bmatrix}$$

Όρια τερματισμού επεισοδίου

Μεταβλητή	Σύμβολο	Όριο τερματισμού
Θέση αμαξιδίου	x	$[-2.4,\ 2.4]$ m
Ταχύτητα αμαξιδίου	$\dot{x}$	Δεν υπάρχει όριο τερματισμού
Γωνία ράβδου	θ	$[-0.2095,\ 0.2095]$ rad ($\pm 12^\circ$)
Γωνιακή ταχύτητα ράβδου	$\dot{\theta}$	Δεν υπάρχει όριο τερματισμού

- Το επεισόδιο λήγει όταν το αμαξίδιο βγει εκτός ορίων ή η ράβδος αποκλίνει υπερβολικά.
- Τα όρια αυτά καθορίζουν το πλαίσιο λειτουργίας και αξιολόγησης των προβλέψεων.

Συλλογή δεδομένων

- Τα δεδομένα συλλέχθηκαν με εκτέλεση πολλών επεισοδίων στο CartPole-v1.
- Σε κάθε χρονικό βήμα καταγράφηκε μετάβαση της μορφής:

$$(\mathbf{x}_t, a_t, \mathbf{x}_{t+1})$$

- Η δυναμική γράφεται γενικά ως:

$$\mathbf{x}_{t+1} = f(\mathbf{x}_t, a_t) + \epsilon_t$$

όπου ϵ_t μοντελοποιεί θόρυβο ή μη μοντελοποιημένες επιδράσεις.

Στόχος συλλογής
Να επιτευχθεί επαρκής κάλυψη του χώρου καταστάσεων, ώστε τα μοντέλα να μάθουν τόσο σταθερές όσο και ασταθείς περιοχές της δυναμικής.

Πολιτικές συλλογής τροχιών

Random Policy -- 95%

- Τυχαία επιλογή μεταξύ $a_t = 0$ και $a_t = 1$.
- Παράγει μεγάλη ποικιλία καταστάσεων.
- Οδηγεί συχνά σε σύντομα επεισόδια λόγω αστάθειας.

PD Controller -- 5%

- Σταθεροποιεί αποτελεσματικά τη ράβδο.
- Παράγει μακρές τροχιές κοντά στην ισορροπία.
- Συμπληρώνει τις περιοχές που δεν καλύπτει η τυχαία πολιτική.

Χρησιμοποιήθηκαν επίσης διαφορετικές αρχικές καταστάσεις και standardization των μεταβλητών για σταθερότερη εκπαίδευση.

Πρόβλημα πρόβλεψης

One-step prediction
Το μοντέλο μαθαίνει να προβλέπει την επόμενη κατάσταση:

$$\hat{\mathbf{x}}_{t+1} = f_\theta(\mathbf{x}_t, a_t)$$

Multi-step prediction
Το ίδιο μοντέλο χρησιμοποιείται αναδρομικά:

$$\hat{\mathbf{x}}_{t+k} = f_\theta(\hat{\mathbf{x}}_{t+k-1}, a_{t+k-1}), \qquad k = 1, \ldots, H$$

Βασική δυσκολία
Σε πολυβηματικές προβλέψεις ανοικτού βρόχου, τα μικρά σφάλματα των πρώτων βημάτων επηρεάζουν όλες τις επόμενες εισόδους και συσσωρεύονται.

Ντετερμινιστικό μοντέλο πρόβλεψης

- Πρώτη προσέγγιση: απλό MLP για πρόβλεψη ενός βήματος.
- Είσοδος: τρέχουσα κατάσταση και ενέργεια $(\mathbf{x}_t, a_t)$.
- Έξοδος: μοναδική πρόβλεψη της επόμενης κατάστασης $\hat{\mathbf{x}}_{t+1}$.
- Εκπαίδευση με Mean Squared Error:

$$\mathcal{L}_{\text{MSE}} = \frac{1}{N} \sum_{i=1}^{N} \left\| \mathbf{x}_{t+1}^{(i)} - \hat{\mathbf{x}}_{t+1}^{(i)} \right\|_2^2$$

- Χρησιμοποιήθηκε Adam optimizer.

Ρόλος
Το ντετερμινιστικό μοντέλο λειτουργεί ως baseline για να αναδειχθεί η ανάγκη εκτίμησης αβεβαιότητας.

Πιθανοτικό μοντέλο πρόβλεψης

Στόχος
Αντί για μία μοναδική πρόβλεψη, το μοντέλο εκτιμά κατανομή πιθανότητας για την επόμενη κατάσταση:

$$p(\mathbf{x}_{t+1} \mid \mathbf{x}_t, a_t)$$

- Το δίκτυο επιστρέφει δύο εξόδους:

$$\boldsymbol{\mu}_{t+1}, \qquad \boldsymbol{\sigma}^2_{t+1}$$

- $\boldsymbol{\mu}_{t+1}$: μέση προβλεπόμενη κατάσταση.
- $\boldsymbol{\sigma}^2_{t+1}$: διακύμανση ανά συνιστώσα κατάστασης.
- Η ενέργεια περνά πρώτα από επίπεδο embedding και έπειτα συνενώνεται με το διάνυσμα κατάστασης.

Αρχιτεκτονική πιθανοτικού μοντέλου

- Action embedding: διάσταση 8.
- Κοινός κορμός δικτύου:
  - 2 πλήρως συνδεδεμένα επίπεδα.
  - 64 νευρώνες ανά επίπεδο.
  - ReLU ενεργοποιήσεις.
  - Dropout με $p = 0.2$.
- Δύο κεφαλές εξόδου:
  - mean head: $\boldsymbol{\mu}$
  - variance head: $\log \boldsymbol{\sigma}^2$

Τελική μορφή

$$(\boldsymbol{\mu}_{t+1}, \boldsymbol{\sigma}^2_{t+1}) = f_\theta(\mathbf{x}_t, a_t)$$

Αριθμητική σταθερότητα

$$\log \boldsymbol{\sigma}^2 \in [-8, 4]$$

$$\boldsymbol{\sigma}^2 = \exp(\log \boldsymbol{\sigma}^2)$$

Αποτελέσματα one-step prediction

Πίνακας 1: Πιθανοτικό μοντέλο

Μετρική	MSE
Συνολικό MSE	**0.006211**
Θέση αμαξιδίου	0.011049
Ταχύτητα αμαξιδίου	0.004592
Γωνία ράβδου	0.005646
Γωνιακή ταχύτητα	0.003556

Πίνακας 2: Deep Ensemble

Μετρική	MSE
Συνολικό MSE	**0.001150**
Θέση αμαξιδίου	0.000114
Ταχύτητα αμαξιδίου	0.001034
Γωνία ράβδου	0.002787
Γωνιακή ταχύτητα	0.000664

Το Deep Ensemble μειώνει το συνολικό MSE περίπου κατά 81% σε σχέση με το απλό πιθανοτικό μοντέλο.

Deep Ensemble

- Χρησιμοποιούνται $M = 5$ ανεξάρτητα πιθανοτικά νευρωνικά δίκτυα.
- Κάθε μοντέλο παράγει δική του μέση τιμή και διακύμανση.
- Η τελική μέση πρόβλεψη είναι:

$$\mu_{ens} = \frac{1}{M} \sum_{i=1}^{M} \mu_i$$

- Η συνολική διακύμανση υπολογίζεται με τον Νόμο της Ολικής Διακύμανσης:

$$\sigma^2_{ens} = \frac{1}{M} \sum_{i=1}^{M} \sigma_i^2 + \mathrm{Var}(\mu_i)$$

Τι κερδίζουμε;
Καλύτερη ακρίβεια και ταυτόχρονη εκτίμηση aleatoric και epistemic uncertainty.

Μέθοδοι διάδοσης αβεβαιότητας

Γιατί χρειάζονται;
Στα multi-step rollouts η αβεβαιότητα δεν αφορά μόνο το επόμενο βήμα. Διαδίδεται και συσσωρεύεται καθώς κάθε πρόβλεψη γίνεται είσοδος για την επόμενη.

1. **Deterministic Mean Propagation**
   - Χρησιμοποιεί μόνο τη μέση πρόβλεψη.
   - Πολύ γρήγορη, αλλά αγνοεί τη διάδοση αβεβαιότητας.
2. **Monte Carlo Propagation**
   - Διαδίδει πολλά sampled particles.
   - Ρεαλιστική αλλά υπολογιστικά ακριβή.
3. **Moment Matching**
   - Αναλυτική διάδοση μέσης τιμής και συνδιακύμανσης.
   - Χρησιμοποιεί γραμμικοποίηση μέσω Jacobian.

Monte Carlo και Moment Matching

Monte Carlo Propagation

$$\mathbf{x}_{t+1}^{(i)} = \boldsymbol{\mu}_{t+1}^{(i)} + \sqrt{\boldsymbol{\sigma}_{t+1}^{2(i)}}\,\boldsymbol{\epsilon}^{(i)}$$

$$\boldsymbol{\epsilon}^{(i)} \sim \mathcal{N}(0, I)$$

- $N = 100$ particles.
- Εμπειρική εκτίμηση μέσης τιμής και διακύμανσης.

Moment Matching

$$\Sigma_{k+1} = J_k \Sigma_k J_k^T + \text{diag}(\sigma_k^2)$$

- Δεν απαιτεί sampling.
- Διαδίδει αναλυτικά τη συνδιακύμανση.
- Πιο αποδοτικό από Monte Carlo, αλλά βασίζεται σε γραμμικοποίηση πρώτης τάξης.

Σύγκριση μεθόδων: Πιθανοτικό μοντέλο

Πίνακας 3: Χρονικός ορίζοντας $H = 20$ για το πιθανοτικό μοντέλο

Μετρική	Det. Mean	Monte Carlo	Moment Matching
MSE ($k = 1$)	0.004815	0.004815	0.004815
MSE ($k = 20$)	0.451964	**0.444988**	0.451964
Variance ($k = 1$)	0.021072	0.021072	0.021072
Variance ($k = 20$)	0.011003	**0.519175**	**0.817581**
Calibration	Overconfident	Καλή	Συντηρητική

- Η Monte Carlo δίνει ελαφρώς μικρότερο τελικό MSE.
- Η Deterministic Mean αποτυγχάνει να αυξήσει τη διακύμανση.
- Η Moment Matching δίνει την πιο συντηρητική εκτίμηση αβεβαιότητας.

Σύγκριση μεθόδων: Deep Ensemble

Πίνακας 4: Χρονικός ορίζοντας $H = 20$ για το Deep Ensemble

Μετρική	**Det. Mean**	**Monte Carlo**	**Moment Matching**
MSE ($k = 1$)	0.001692	0.001692	0.001692
MSE ($k = 20$)	**0.012859**	0.015300	**0.012859**
Variance ($k = 1$)	0.001217	0.001217	0.001217
Variance ($k = 20$)	0.001175	**0.065788**	**0.077713**
Calibration	Overconfident	Καλή	Συντηρητική

- Το Ensemble μειώνει δραστικά το tracking error.
- Η Monte Carlo εισάγει μικρή πρόσθετη στοχαστικότητα.
- Η Moment Matching διατηρεί ακρίβεια και παρέχει συντηρητική αβεβαιότητα.

Ερμηνεία γραφημάτων

- Τα γραφήματα error vs horizon δείχνουν τη συσσώρευση σφάλματος όσο αυξάνεται το *k*.
- Τα γραφήματα variance vs time δείχνουν ότι:
  - η Deterministic Mean παραμένει σχεδόν επίπεδη,
  - η Monte Carlo και η Moment Matching αυξάνουν την αβεβαιότητα.
- Τα calibration plots συγκρίνουν πραγματικό σφάλμα και προβλεπόμενη αβεβαιότητα.
- Στο Deep Ensemble, οι καμπύλες είναι πιο σταθερές και οι προβλέψεις σαφώς πιο αξιόπιστες.

Κεντρική παρατήρηση
Η αβεβαιότητα δεν μειώνει πάντα το σημειακό MSE, αλλά δείχνει πότε οι μακροπρόθεσμες προβλέψεις παύουν να είναι αξιόπιστες.

Βασικά συμπεράσματα

- Η one-step πρόβλεψη είναι σχετικά εύκολη, αλλά η multi-step πρόβλεψη είναι δυσκολότερη λόγω συσσώρευσης σφάλματος.
- Το απλό πιθανοτικό μοντέλο παρέχει μέση τιμή και διακύμανση, αλλά έχει υψηλότερο MSE.
- Το Deep Ensemble βελτιώνει σημαντικά την ακρίβεια και την αξιοπιστία.
- Η Deterministic Mean είναι υπολογιστικά φθηνή, αλλά υπερβολικά αισιόδοξη.
- Η Monte Carlo είναι πιο γενική, αλλά ακριβή υπολογιστικά.
- Η Moment Matching προσφέρει καλή ισορροπία μεταξύ κόστους, ακρίβειας και συντηρητικής αβεβαιότητας.

Περιορισμοί και μελλοντικές βελτιώσεις

Περιορισμοί

- Το CartPole είναι σχετικά απλό σύστημα.
- Η Monte Carlo έχει αυξημένο υπολογιστικό κόστος.
- Η Moment Matching βασίζεται σε τοπική γραμμικοποίηση.
- Η αξιολόγηση έγινε σε περιορισμένο χρονικό ορίζοντα.

Μελλοντική εργασία

- Διαχωρισμός aleatoric και epistemic uncertainty.
- Δοκιμή σε πιο σύνθετα δυναμικά συστήματα.
- Χρήση uncertainty-aware MPC.
- Μελέτη μεγαλύτερων οριζόντων πρόβλεψης.

Τελικό μήνυμα

Η εκτίμηση αβεβαιότητας είναι κρίσιμη για αξιόπιστες προβλέψεις μεγάλου χρονικού ορίζοντα.

Συνολική επιλογή
Ο συνδυασμός Deep Ensemble με Moment Matching προσφέρει την καλύτερη ισορροπία ανάμεσα σε:

- ακρίβεια πρόβλεψης,
- ρεαλιστική διάδοση αβεβαιότητας,
- στατιστική ασφάλεια,
- υπολογιστικό κόστος.

Ευχαριστώ!

Ερωτήσεις;